INSTRUCCIONES 3er EXAMEN PARCIAL

Examen parcial | Limpieza y transformación de datos con pandas

Asignatura: Análisis Exploratorio de datos **Modalidad:** Individual, entrega en Google Colab
Valor: 5.0 puntos **Tiempo disponible: 72 horas desde la publicación del dataset**

1. Contexto del conjunto de datos

El archivo prescripciones_hospitalarias_raw.csv contiene 520 registros simulados de un sistema de prescripción hospitalaria. Los datos representan el estado real que puede encontrarse en sistemas de información clínica: entradas manuales sin validación, exportaciones de múltiples fuentes con formatos heterogéneos y errores de digitación acumulados.

El dataset incluye las siguientes columnas:

Columna	Tipo aparente	Descripción
id_paciente	int / object	Identificador numérico del paciente. Contiene duplicados parciales.
fecha_prescripcion	object	Fecha en tres formatos distintos: YYYY-MM-DD, DD/MM/YYYY y texto en español.
medicamento	object	Nombre del fármaco. Variaciones en mayúsculas, espacios y abreviaciones.
dosis_mg	object	Dosis en miligramos. Mezcla de números, strings como '100mg', valores negativos y NaN.
via_administracion	object	Vía de administración. Múltiples formas para la misma categoría.
diagnostico_cie10	object	Código CIE-10 o texto libre. Contiene NaN.
peso_paciente_kg	float	Peso en kilogramos. Incluye outliers fisiológicamente imposibles y NaN.
edad	float / object	Edad del paciente. Valores negativos, NaN y tipo heterogeneo.
eps	object	Nombre de la EPS. Múltiples variantes para la misma entidad.
prescriptor_id	object	Identificador del médico prescriptor. Contiene NaN y formato variable.

2. Instrucciones generales

- Descargue el archivo CSV desde el enlace entregado por el docente y súbalo a su Google Drive o cárguelo directamente en Colab.
- Organice el notebook con celdas de texto (Markdown) que identifiquen cada nivel y tarea. El código sin estructura narrativa no recibe puntaje completo.

- Cada decisión de limpieza debe estar justificada en texto. No es suficiente ejecutar una función; debe explicar por qué eligió esa estrategia.
- El script debe ejecutarse de principio a fin sin errores. Use un bloque try/except o validaciones previas si una transformación puede fallar.
- Nombre del archivo de entrega: prescripciones limpias_[apellido].csv. Incluya el enlace compartido del notebook en el encabezado de este.

3. Tareas por nivel

Nivel 1: Diagnostico (1.25 puntos)

Objetivo: construir un inventario preciso del estado del dataset antes de cualquier intervención.

1. Cargue el dataset con pandas. Reporte forma, tipos de dato, nombres de columnas y las primeras cinco filas.
2. Calcule el número y porcentaje de valores faltantes por columna. Presente los resultados en una Serie o DataFrame ordenado de mayor a menor completitud.
3. En una celda Markdown, documente cada problema encontrado por columna. Incluya el tipo de problema (tipo incorrecto, valor invalido, inconsistencia categórica, duplicados, etc.) y un ejemplo concreto.

Nivel 2: Limpieza (2.5 puntos)

Objetivo: transformar cada columna al estado que permite análisis confiable.

4. Estandarice fecha_prescripcion a tipo datetime. Use pd.to_datetime con errors='coerce'. Justifique que hace con los NaT resultantes.
5. Limpie dosis_mg: (a) extraiga el valor numérico de strings mixtos como '100mg', (b) decida como tratar valores negativos y justifique su criterio, (c) impute los NaN con la mediana por medicamento usando groupby y transform.
6. Normalice medicamento y via_administracion: elimine espacios, convierta a minúsculas y construya un diccionario de mapeo para unificar equivalentes (por ejemplo, 'VO', 'oral', 'Oral', 'via oral' deben converger en una forma canónica).
7. Detecte y trate outliers en peso_paciente_kg usando el método del rango intercuartílico (IQR). Decida entre eliminar o imputar y justifique. Muestre la distribución antes y después con .describe().
8. Identifique y elimine duplicados exactos y duplicados parciales definidos como registros con el mismo id_paciente, fecha_prescripcion y medicamento. Reporte cuantos registros se eliminaron en cada caso.
9. Unifique las variantes de eps en categorías canónicas. Puede usar un diccionario de mapeo manual. Reporte la cardinalidad antes y después.

Nivel 3: Transformación y validación (1.25 puntos)

Objetivo: generar variables derivadas y garantizar la integridad del dataset final.

10. Cree la columna rango_etario con las categorías: 'pediátrico' (edad < 18), 'adulto' (18 a 64) y 'adulto mayor' (>= 65). Asigne 'desconocido' a filas con edad invalida o NaN.

11. Construya una tabla resumen agrupada por eps y via_administracion que incluya conteo de prescripciones y estadísticas descriptivas de dosis_mg limpia.
12. Exporte el DataFrame limpio como CSV con el nombre prescripciones_limpias_[apellido].csv, sin columna de índice duplicada.

4. Rubrica de evaluación

Criterio	Descripción del desempeño esperado	Pts
NIVEL 1: Diagnostico (1.25 puntos)		
Carga e inspección inicial	Usa .info(), .describe(), .shape y .dtypes correctamente. Identifica dimensiones del dataset.	0.25
Inventario de valores faltantes	Calcula .isnull().sum() y porcentaje de completitud por columna. Presenta tabla o serie ordenada.	0.5
Documentación de problemas	Celda de texto Markdown que lista cada problema identificado por columna, con tipo de problema y ejemplo.	0.45
NIVEL 2: Limpieza (2.5 puntos)		
Estandarización de fechas	Convierte fecha_prescripcion a datetime con pd.to_datetime(..., errors='coerce'). Justifica decisión sobre NaT resultantes.	0.4
Limpieza de dosis_mg	Extrae valores numéricos de strings mixtos (ej.., '100mg'), trata negativos con criterio justificado, imputa NaN. No acepta dropna() sin justificacion.	0.5
Normalización de texto categórico	Estandariza medicamento y via_administracion: strip, lower, mapeo de equivalencias. Reduce cardinalidad correctamente.	0.5
Tratamiento de outliers	Aplica método IQR a peso_paciente_kg. Justifica si elimina o imputa. Muestra distribucion antes y después.	0.4
Manejo de duplicados	Identifica y elimina duplicados exactos y parciales (mismo id + fecha + medicamento). Reporta cuantos elimino.	0.35
Corrección de variantes en eps	Agrupa variantes de una misma EPS mediante mapeo manual o lógica de normalización. Reduce a categorías canónicas.	0.5
NIVEL 3: Transformación y validación (1.25 puntos)		
Creación de rango_etario	Columna derivada con categorías: pediátrico (<18), adulto (18-64), adulto mayor (>=65). Maneja NaN y edades invalidas.	0.45
Tabla resumen	GroupBy por eps y via_administracion con conteo y estadística descriptiva de dosis_mg limpia. Formateada y legible.	0.4
Exportación del CSV limpio	Guarda DataFrame con nombre prescripciones_limpias_[apellido].csv. Sin columnas de índice duplicadas.	0.25
	TOTAL	**5.0**

5. Penalizaciones

Las siguientes conductas generan descuentos adicionales sobre el puntaje obtenido:

Conducta penalizada	Descuento
Uso de .dropna() sin justificacion escrita en celda Markdown	-0.5 pts
Ausencia de comentarios en celdas de código	-0.25 pts
Script no ejecutable de principio a fin sin errores	-0.75 pts
No exportar el CSV final con el nombre indicado	-0.25 pts
Celdas de código sin organización por nivel o sección	-0.15 pts

6. Criterio de evaluación transversal

Mas allá del código correcto, se evalúa la calidad del razonamiento. El estudiante que usa .dropna() para resolver todos los problemas de valores faltantes sin justificacion escrita no comprende que la imputación y la eliminación tienen consecuencias distintas sobre el análisis posterior. El examen mide esa comprensión, no la capacidad de ejecutar funciones de memoria.

Un dataset de salud con valores faltantes en peso o edad no es simplemente un problema técnico: representa información clínica ausente con consecuencias reales. Se espera que el estudiante reconozca esa dimensión en sus justificaciones.

8. Formato de entrega

- Enlace al notebook de Google Colab con permisos de visualización activados (cualquier persona con el enlace puede ver).
- Archivo CSV exportado subido al mismo Drive y con enlace incluido en la celda de encabezado del notebook.
- Plazo: 72 horas después de la publicación del dataset en mi correo gbruges@unab.edu.co

---

Cualquier consulta de carácter técnico debe publicarse en el foro del aula virtual. No se responden preguntas por mensajes privados durante el periodo de examen.

Gustavo Bruges-Morales
Biólogo /Farmacólogo. PhD./M.Sc. Ciencia de Datos
Docente Departamento de Ciencias